

Parkinson Hastalığı Teşhisi için Yapay Arı Kolonisi Temelli Öznitelik Seçimi

Feature Selection Based on Artificial Bee Colony for Parkinson Disease Diagnosis

Hasan BADEM, Duran TURKUSAGI
Bilgisayar Mühendisliği
Kahramanmaraş Sütçü İmam Üniversitesi
Kahramanmaraş, Türkiye
hbadem@ksu.edu.tr, duranturkusagi@gmail.com

Abdullah CALISKAN
Biyomedikal Mühendisliği
İskenderun Teknik Üniversitesi
Hatay, Türkiye
abdullah.caliskan@iste.edu.tr

Zeynel Abidin ÇİL
Endüstri Mühendisliği
İzmir Demokrasi Üniversitesi
İzmir, Türkiye
zabidin.cil@idu.edu.tr

Özetçe —Parkinson hastalığının ses sinyalleri üzerinden teşhis edilebilmektedir. Ses sinyallerinden öznitelik çıkarma algoritmaları ile elde edilen veriler doğrudan sınıflandırma algoritmalarında kullanılmaktadır. Çıkarılan özniteliklerin bazıları ilgili problemi temsil etme kabiliyeti yüksek iken bazılarının düşüktür. Parkinson hastalığı teşhisinde ses sinyallerinden elde edilen özniteliklerden hangilerinin sınıflandırma başarımını artırabileceğinin tespit edilebilmesi oldukça önemlidir. Bu çalışmada bahsi geçen problemin çözümü için Yapay Arı Kolonisi algoritması temelli öznitelik seçim yaklaşımı önerilmiştir. Önerilen yöntem, literatüre yaygın kabul gören destek vektör makinesi, K en yakın komşu, Naive Bayes ve karar ağaçları sınıflandırma yöntemleriyle karşılaştırmalı olarak analiz edilmiştir.

Anahtar Kelimeler—Parkinson hastalığı, Öznitelik seçimi, Yapay arı kolonisi

Abstract—Parkinson's disease can be diagnosed by the speech signals. In general, the data obtained by feature extraction algorithms from the speech signals are used in any classification algorithm. Some of the extracted features have a high ability to represent the relevant problem, while others are low. In the diagnosis of Parkinson's disease, it is very important to determine which of the extracted features from the speech signals may increase the classification performance. In this paper, Artificial Bee Colony algorithm based feature selection approach is proposed for the solution of the mentioned problem. The proposed method has been analyzed in comparison with the well-known classification methods including support vector machine, k nearest neighbor, Naive Bayesian, decision tree.

Keywords—Parkinson disease, Feature selection, Artificial bee colony

I. GİRİŞ


Parkinson, yaşlılık döneminde Alzheimer hastalığından sonra görülen en yaygın hastalıktır [1]. Parkinson hastalığının, mevcut yöntemlerle tamamen tedavi edilememektedir. Fakat, hastalığın erken döneminde teşhisi ve takibi hastanın yaşam konforunun artırılmasında önemli rol oynamaktadır. Parkinson hastalarının fiziksel hareketlerinde yavaşlama, kas

kontrol kaybı, uzuvlarda titreme ve konuşma bozuklukları vb. karakteristik belirtiler bulunmaktadır [2], [3]. Bahsi geçen belirtiler tam olarak gözlenmeden erken tanı döneminde teşhis edilebilmesi, yaşam konforunun artırılmasında fayda sağlayacaktır. Erken tanı döneminde, hastaların konuşma bozukluklarından hastalığın teşhisi ve ilerlemesinin takip edilmesi üzerine yapılan pek çok çalışma literatürde bulunmaktadır [4], [5].


Parkinson hastalığını, konuşma bozukluğundan tanımlamak özenle gerçekleştirilmesi gereken zorlu bir takım süreçleri gerektirmektedir [6]–[8]. Bu süreçte, öncelikle ses sinyalleri bazı filtreleme teknikleriyle gürültüden arındırılmalıdır. Sonrasında gürültüden arındırılan ses sinyalleri üzerinden parkinson hastalığını en iyi biçimde temsil edebilecek özniteliklerin elde edilmesi gerekmektedir. Daha sonra elde edilen öznitelikler kullanılarak uygun bir sınıflandırma algoritmasıyla ile hastalık teşhis edilir [1]. Bu süreçte, problemi temsil edebilecek özniteliklere karar verildikten sonra, doğrudan tüm öznitelikler kullanılmaktadır. Fakat, hangi öznitelik çıkarma yöntemi kullanılırsa kullanılsın, bazı öznitelik vektörlerinin diğerlerine göre baskın olabileceği veya bazı öznitelik vektörlerinin hastalık teşhisinde sonuca fazla katkı sağlamayabileceği durumu ihmal edilmektedir. Bahsedilen bu sınırlılığın ortadan kaldırabilmesi adına, elde edilen özniteliklerden hangilerinin problemin çözümünde daha etkin olduğunun karar verilebilmesi süreci bir optimizasyon problemi olarak tanımlanabilir.

Literatürde, bir fonksiyonun optimizasyon için sunulan pek çok yöntem bulunmaktadır. Fakat, bu yöntemlerden Parçacık Sürü Optimizasyon [9], Genetik Algoritma [10] ve Yapay Arı Kolonisi (Artificial Bee Colony-ABC) [11] küresel en iyi çözümü bulmada etkin sonuç üretmektedir. ABC Algoritması, test fonksiyonları üzerindeki başarısı dikkate alındığında, nispeten daha etkin bir algoritma olduğu belirtilmektedir [12], [13].

Bu çalışmada, Parkinson hastalığının teşhisinde ses sinyalleri üzerinden çeşitli yöntemlerle elde edilen özniteliklerden etkin olanların, ABC algoritması ile seçilmesi amaçlanmaktadır. Ayrıca önerilen yaklaşımla seçilen özniteliklerin sınıflandırma sürecinde, literatürde kabul gören



Şekil 1: Genel Parkinson Hastalığı Teşhis Süreci



Şekil 2: Önerilen Parkinson Hastalığı Teşhis Süreci

Destek Vektör Makinesi (Support Vector Machine, SVM), K-en Yakın Komşu (K-nearest neighbor-KNN) algoritması, Karar Ağaçları (Decision Tree, DT) ve Naive Bayes (NB) sınıflandırıcıların kullanılan veri setindeki performansının değerlendirilmesi amaçlanmaktadır.

Çalışmanın ikinci bölümünde, önerilen yöntem ve karşılaştırma ölçütleri sunulmaktadır. Daha sonra, deneysel sonuçlar verilmektedir. Çalışma sonuç bölümü ile sonlandırılmaktadır.

II. YÖNTEM

Parkinson hastalığı teşhisi sürecinde, Şekil 1'de görülen genel yaklaşım uygulanmaktadır. Bu yaklaşımda, ses sinyalleri ham veri olarak kullanılmaktadır. Elde edilen ses sinyallerinden gürültülerin filtrelenme süreci ön işlemdir [14]. Filtrelenmiş veriden çeşitli öznitelik çıkarma algoritmalarıyla, problemi temsil edebilecek veri oluşturulmaktadır. Elde edilen bu veriler bir sınıflandırma algoritması ile hastalık teşhisi yapılmaktadır. Fakat bu genel yaklaşımda, öznitelik çıkarma algoritmalarından elde edilen verideki bazı vektörlerin probleme özgü olarak anlamlı yada anlamsız olduğuna bakılmaksızın kullanılmaktadır. Bu durum hastalık teşhisinde, başarıyı oldukça etkilemektedir. Bu çalışmada, parkinson hastalığı teşhisi sürecinde bahsi geçen problemin ortadan kaldırılması adına ABC algoritması temelli öznitelik seçme yaklaşımı önerilmektedir. Önerilen yöntemin genel yaklaşımdaki geliştirilmiş blok diyagramı Şekil 2'de görülmektedir. Önerilen yöntem aşağıda alt bölümler halinde sunulmaktadır.

A. Yapay Arı Kolonisi Optimizasyon Algoritması

ABC algoritması, bal arılarının yiyecek arama sürecinde göstermiş oldukları zeki davranışları modelleyen bir optimizasyon algoritmasıdır. Bu zeki yiyecek arama süreci; görevli, gözcü ve kâşif arı olmak üzere 3 arı türü ile gerçekleştirilmektedir [11].

Görevli arılar, daha önce keşfedilmiş besin kaynakları civarında araştırma yapar ve sorumlu olduğu kaynaktan besin taşımaktadır. Görevli arılar kovana döndüklerinde, sorumlu olduğu besin kaynağının yeri ve nektar kalitesi hakkında gözcü arılara titreşim dansı üzerinden bilgi aktarır. Gözcü arılar ise, izlemiş oldukları danslar elde ettikleri bilgilere göre bir besin kaynağı seçer ve araştırma işlemlerini seçmiş olduğu kaynak üzerinden gerçekleştirmektedir. Görevli arılar, sorumlu oldukları besin kaynağı tükenmiş yada kalitesi yetersiz olursa araştırmalarına kâşif arı olarak devam etmektedir. Kâşif

arılar ise, rastgele bir alternatif besin kaynağı araştırmaktadır [15]–[19].

Bal arılarının yukarıda bahsedilen sürü zekasını modelleyen ABC algoritması, Derviş KARABOĞA tarafından literatüre sunulmuştur [11]. ABC algoritmasında her bir besin kaynağı, bir aday çözüme karşılık gelmektedir. Aynı zamanda besin kaynaklarının nektar miktarı, aday çözümün uygunluk değerine olarak tanımlanmaktadır. En iyi çözümü araştırma sürecinde tüm arı türleri iteratif fazlar halinde araştırma yapmaktadır [15]–[19].

ABC algoritması, D adet rastgele değerlerden oluşan SN farklı besin kaynağı oluşturularak başlatılır [15], [16]. Bu işlem denklem 1'de tanımlanmaktadır.

$$x_{ij} = x_j^{min} + rand(0, 1)(x_j^{max} - x_j^{min}) \quad (1)$$

burada; x_{ij} , i . çözümün j . parametresine karşılık gelmektedir. x_{jmin} ve x_{jmax} ise j . parametrenin alt ve üst sınır değerleridir [15], [16].

Görevli arılar, sorumlu olduğu ve rastgele seçilen bir besin kaynağının bilgilerini kullanarak, yeni bir çözüm araştırmaya çalışır. Bu süreç aşağıdaki denklem ile modellenmiştir [15], [16];

$$v_{ij} = x_{ij} + \phi_{ij}(x_{ij} - x_{kj}) \quad (2)$$

burada, k ve j indeksleri rastgele seçilen değerlerdir. Elde edilen yeni çözümün uygunluk değeri, var olan çözümünden daha kaliteli ise, görevli arı yeni çözüm ile güncellenmektedir. Tüm görevli arılar araştırma süreçlerini tamamladıktan sonra, sorumlu oldukları besin kaynaklarının kalite bilgisini gözcü arılar ile paylaşmaktadır. Her bir gözcü arı, var olan çözümlerin olasılık değerine göre, bir çözüm seçer ve görevli arı gibi denklem 2 üzerinden aday bir çözüm üretmektedir [15], [16]. Besin kaynaklarının olasılık değerleri aşağıdaki denklem ile hesaplanmaktadır:

$$p_i = \frac{fitness_i}{\sum_{j=1}^{SN} fitness_j} \quad (3)$$

Meta-sezgisel algoritmalarının araştırma sürecinde, keşif ve tüketimin işlemleri arasında bir denge olmak zorundadır. ABC algoritmasında bu denge *limit* adı verilen bir kontrol parametresi ile sağlanmaktadır. Bu parametre ile besin kaynaklarının deneme sayısı kontrol edilir. ABC algoritmasının her çevriminde, *limit* değerini en çok geçen besin kaynağı terk edilir ve sorumlu görevli arı, kâşif arı olarak aday bir çözüm üretmektedir. *limit* parametresi literatürde genellikle aşağıdaki denklem üzerinden belirlenir [15], [16].

$$limit = \lceil a \times SN \times D \rceil \quad (4)$$

B. Öznitelik Seçimi

Öznitelik seçim işlemi bir optimizasyon problemi olarak tasarlandığında, veri setinde çözümü temsil kabiliyeti yüksek öznitelik vektörlerinin bulunması amaçlanmaktadır. Dolayısı ile veri setindeki problemi temsil gücü zayıf olan öznitelik vektörlerinin veri setinden çıkarılarak geliştirilen sınıflandırma modelinin doğruluk değerini yükseltilmeye çalışılmaktadır.

Parkinson hastalığı teşhisinde kullanılacak herhangi bir veri setindeki her bir X_i giriş vektörüne karşılık bir çıkış Y_i etiketine sahiptir. Bu çalışmada kullanılan veri setinde, 240

örneklem ve 46 adet öznitelik bulunmaktadır. Veri setindeki 46 adet öz nitelikten Parkinson hastalığının ses sinyalleri üzerinden teşhis edilebilmesinde, daha etkin olduğunun belirlenmesinde ABC temelli öznitelik seçimi gerçekleştirilmiştir.

ABC temelli öznitelik seçiminde, aday her bir çözümün uygunluk değeri KNN sınıflandırma algoritması ile 10 kat çapraz doğrulama tekniği kullanarak hesaplanmıştır. Şekil 3-a'da görüldüğü üzere ABC algoritmasının başlangıç aşamasında; her bir besin kaynağı için araştırma yaparken problemin temsiline kullanılabilecek her bir öznitelik vektörünü temsilen (0,1) arasında rastgele reel sayılar oluşturulmuştur. Bu reel değerler üzerinden araştırma yapılırken, besin kaynağının uygunluk değeri hesaplanırken önceden belirlenen bir eşik değerine göre 0 veya 1 değerinde seçim vektörü oluşturulmaktadır. Bu durum Şekil 3-b'de görülmektedir. ABC algoritmasında, çözüm uzayını temsil

	1	2	...	D
1	0,13	0,72	...	0,44
2	0,91	0,25	...	0,68
⋮	⋮	⋮	⋮	⋮
SN	0,37	0,96	...	0,37

(a) Araştırma

	1	2	...	D
1	0	1	...	0
2	1	0	...	1
⋮	⋮	⋮	⋮	⋮
SN	0	1	...	0

(b) Uygunluk

Şekil 3: ABC algoritmasında besin kaynaklarının temsili

eden her bir besin kaynağının parametre sayısı (D), Parkinson hastalığı teşhisi için oluşturulan veri setindeki öznitelik sayısına eşittir. Öznitelik seçim vektöründe kullanılan eşik değeri 0.5 alınmıştır. ABC algoritması temelli öznitelik seçim sürecinde, besin kaynağı sayısı; 10, 20, 40, 50 ve 100 alınmıştır. Ayrıca, çevrim sayısı ise 10, 100, 500 ve 1000 alınmıştır. Bu kontrol parametrelerinin her bir kombinasyonu için önerilen algoritma çalıştırılmıştır. En yüksek doğruluk oranını, besin kaynağı 20 ve çevrim sayısı 1000 olan kombinasyon vermiştir. Deneysel sonuçlar bu kombinasyon üzerinden elde edilmiştir.

III. DENEYSEL SONUÇLAR VE TARTIŞMA

Deneysel sonuçları elde edebilmek için UCI makine öğrenmesi deposunda 2019 yılında paylaşılmış olan "Akustik Özelliklere Sahip Parkinson Veri Kümesi" veri seti [20], [21] kullanılmıştır. Makine öğrenmesi yöntemlerini karşılaştırmak için 10 kat çapraz doğrulama tekniği ile 30 farklı koşma gerçekleştirilmiştir. Elde edilen sonuçlar, 2.0 GHz Intel i7-4510 işlemcili ve 12 GB RAM belleğe sahip sistem üzerinden elde edilmiştir.

Bu bölümde, öncelikle kullanılan veri setinden bahsedilmekte, daha sonra karşılaştırmalı olarak elde edilen simülasyon sonuçları sunulmaktadır.

A. Akustik Özelliklere Sahip Parkinson Veri Kümesi veri seti

Akustik Özelliklere Sahip Parkinson Veri Kümesi (Parkinson Dataset with replicated acoustic features-PDRAF) veri setinin geliştirilme amacı, bireylerin ses kayıtları üzerinden hastalığın tespit edilebilmesi için klinik uzman

sistem geliştirmektir. Bu amaç için bireylerin ses kayıtlarından özellikler çıkararak örüntü tanıma için gelişmiş bir istatistiksel yaklaşım göz önünde bulunduran veri seti oluşturulmuştur [20]. PDRAF veri seti 2019 yılında UCI Makine öğrenmesi [22] deposundan paylaşılmıştır. Literatürde ses sinyalleri üzerinden Parkinson hastalığının teşhis edilebilmesi için birkaç veri seti daha bulunmaktadır. PDRAF diğer veri setleri arasında, bu çalışmanın yapıldığı tarihe göre en güncel veri setidir. PDRAF veri seti için kullanılan Parkinson Hastalığına sahip hastalar İspanya Ekstremadura Bölgesel Parkinson Hastalığı Derneği üyelerinden seçilmiştir [20]. PDRAF veri seti oluşturulurken çalışmaya 50 yaşından büyük 80 kişi katılmıştır. Hastaların 40'ı sağlıklı: 22 erkek (%55) ve 18 kadın (%45) ve 40'ı PD: 27 erkek (%67,5) ve 13 kadın (%32,5) tarafından oluşmaktadır. Ortalama yaş, kontrol grubu için 66,38 ve PD'li kişilerde 69,58 dir.

Ses kayıtları, deneklere "a" ünlü harfinin rahat ve yüksek sesle en az 5 saniye ve bir nefeste söylenmesiyle elde edilmiştir. Veri toplama süreci, kişi başına üç kez tekrarlanmıştır [20]. Dijital kayıt, Audacity yazılımı (sürüm 2.0.5) kullanılarak 44.1 KHz örnekleme hızında ve 16 bit/örnek çözünürlükte yapılmıştır [20].

B. Simülasyon Sonuçları

ABC algoritmasıyla elde edilen en iyi öznitelik vektörleri, tüm karşılaştırma yöntemlerinde kullanılarak deneysel sonuçlar elde edilmiştir. Parkinson hastalığının teşhis edilebilmesi için, PDRAF veri seti üzerinden SVM, KNN, DT ve NB sınıflandırıcıları 10 kat çapraz doğrulama tekniği ile 30 farklı koşma gerçekleştirilmiştir. Gerçekleştirilen bu simülasyonlardan, 30 farklı koşmanın *acc*, *AUC*, *sn*, *sp*, *f*, *p* değerleri kaydedilmiştir. Bu değerlerin ortalama ve standart sapmaları Tablo I, Tablo II ve Tablo III'te verilmiştir. Tablo I incelendiğinde; 82,37 ile en yüksek ortalama

	<i>acc</i>		<i>AUC</i>	
	Ortalama	Standart Sapma	Ortalama	Standart Sapma
SVM	73,347	0,850	71,142	2,206
KNN	82,375	1,248	82,086	2,165
DT	67,986	2,237	67,410	2,488
NB	61,263	1,196	64,375	2,685

Tablo I: SVM, KNN, DT ve NB sınıflandırıcılarının 30 koşmadaki *acc* ve *AUC* ölçütlerinin ortalama ve standart sapma değerleri

	<i>sn</i>		<i>sp</i>	
	Ortalama	Standart Sapma	Ortalama	Standart Sapma
SVM	61,047	2,024	81,630	1,190
KNN	78,296	2,069	85,208	1,521
DT	61,515	3,390	72,604	2,841
NB	78,451	1,649	49,733	1,769

Tablo II: SVM, KNN, DT ve NB sınıflandırıcılarının 30 koşmadaki *sn* ve *sp* ölçütlerinin ortalama ve standart sapma değerleri

doğruluk değerine KNN algoritması sahipken, daha sonra SVM algoritması ile ortalama 73,34 doğruluk değeri elde edilmiştir. DT ve NB yöntemleri sırasıyla 67,98; 61,26 ortalama doğruluk değerleri elde edilmiştir. Doğruluk değerleri incelendiğinde, diğer yöntemler ile KNN arasında, KNN

	f		p	
	Ortalama	Standart Sapma	Ortalama	Standart Sapma
SVM	63,385	1,664	69,095	2,10
KNN	77,298	1,674	78,519	2,254
DT	59,156	2,763	60,032	3,301
NB	60,948	1,081	51,368	1,051

Tablo III: SVM, KNN, DT ve NB sınıflandırıcılarının 30 koştaki f ve p ölçütlerinin ortalama ve standart sapma değerleri

algoritmasının lehine önemli bir fark olduğu görülmektedir. Aynı zamanda, KNN algoritması, DT ve NB yöntemlerine göre oldukça üstün bir doğruluk değeri elde ettiği Tablo I'de görülmektedir. Sınıflandırma algoritmalarının başarılarını karşılaştırmada en önemli ölçütlerden olan AUC değerlerinde de KNN algoritmasının, diğer yöntemlere göre üstün bir başarı elde ettiği görülmektedir. sn açısından Tablo II incelendiğinde, Parkinson hastalığına sahip bireyleri doğru olarak tespit edebilme başarımında, NB ve KNN algoritması karşılaştırıldığında NB algoritmasının lehine bir fark olduğu görülmektedir. Aynı zamanda, NB algoritmasının, DT ve SVM algoritmalarına göre üstün bir başarı gösterdiği görülmektedir. Fakat, Parkinson hastalığı bulunmayan bireylerin doğru olarak tespit edilebilmesinde KNN sınıflandırıcısının SVM ve DT yöntemlerine göre daha başarılı olduğu görülmektedir. Aynı zamanda, KNN algoritmasının NB algoritmasına göre oldukça üstün bir başarı elde ettiği anlaşılmaktadır.

Parkinson hastalığına sahip olduğu tahmin edilen bireylerin gerçekte ne kadarının hastalığa sahip olduğunu gösteren p ölçütüdür. Tablo 3 bu açıdan incelendiğinde; KNN sınıflandırıcısı, SVM,DT ve NB yöntemlerine göre üstün bir başarı elde ettiği görülmektedir. f açısından Tablo III değerlendirildiğinde ise, KNN sınıflandırıcısının, diğer yöntemlere göre üstün bir başarı elde ettiği görülmektedir.

Karşılaştırma ölçütleri genel olarak değerlendirildiğinde, KNN algoritması rakip algoritmalara göre üstünlük sağladığı anlaşılmaktadır.

IV. SONUÇ

Bu çalışmada, Parkinson hastalığının ses sinyalleri üzerinden teşhis edilebilmesi için ABC algoritması temelli öznelik seçim modeli önerilmiştir. Önerilen model ile elde edilen öznelikler, geleneksel sınıflandırma yöntemlerinde karşılaştırmalı olarak test edilmiştir. Elde edilen deneysel sonuçlarda KNN algoritması ile sınıflandırma sonuçlarının daha yüksek olduğu ortaya çıkmıştır. Önerilen yöntem ile Parkinson hastalığının teşhisinde kullanılabilecek özneliklerden hangilerinin problemi temsil kabiliyetinin daha yüksek olduğu belirlenebilmektedir. Bu açıdan önerilen yöntem ile hastalığının teşhisinde kullanılabilecek tüm sınıflandırma algoritmalarının başarımını artırabilir.

Parkinson hastalığının konuşma bozuklukları dışında hareket bozuklukları, koordinasyon zayıflaması vb. birçok belirtisi daha bulunmaktadır. Bu belirtileri de kapsayacak yeni özneliklere sahip yeni veri setlerinde de önerilen yöntemin başarımının araştırılması hastalık teşhisinde doğruluk oranını artırabileceği düşünülebilir. Bu nedenle, bu alandaki gerçekleştirilebilecek yeni araştırmalar hasta konforu açısından önem arz etmektedir.

KAYNAKÇA

- [1] R. C. Deo, "Machine learning in medicine," *Circulation*, vol. 132, no. 20, pp. 1920–1930, 2015.
- [2] C. O. Sakar, G. Serbes, A. Gunduz, H. C. Tunc, H. Nizam, B. E. Sakar, M. Tutuncu, T. Aydin, M. E. Isenkul, and H. Apaydin, "A comparative analysis of speech signal processing algorithms for parkinson's disease classification and the use of the tunable q-factor wavelet transform," *Applied Soft Computing*, vol. 74, pp. 255 – 263, 2019.
- [3] R. Cakmur, "Parkinson hastalığı ve medikal tedavisi," *Klinik Gelişim*, pp. 53–58, 2011.
- [4] H. Gürler, "A novel diagnosis system for parkinson's disease using complex-valued artificial neural network with k-means clustering feature weighting method," *Neural Computing and Applications*, vol. 28, no. 7, pp. 1657–1666, 2017.
- [5] M. Peker, "A decision support system to improve medical diagnosis using a combination of k-medoids clustering based attribute weighting and svm," *Journal of medical systems*, vol. 40, no. 5, p. 116, 2016.
- [6] A. Caliskan, H. Badem, A. Basturk, and M. E. Yuksel, "Diagnosis of the parkinson disease by using deep neural network classifier," *Istanbul University-Journal of Electrical & Electronics Engineering*, vol. 17, no. 2, pp. 3311–3318.
- [7] H. Badem, "Parkinson hastalığının ses sinyalleri Üzerinden makine Öğrenmesi teknikleri ile tanımlanması," *Ömer Halisdemir Üniversitesi Mühendislik Bilimleri Dergisi*, vol. 8, pp. 630 – 637, 2019.
- [8] H. Gunduz, "Deep learning-based parkinson's disease classification using vocal feature sets," *IEEE Access*, vol. 7, pp. 115 540–115 551, 2019.
- [9] R. Poli, J. Kennedy, and T. Blackwell, "Particle swarm optimization," *Swarm Intelligence*, vol. 1, no. 1, pp. 33–57, Jun 2007.
- [10] J. H. Holland, K. J. Holyoak, R. E. Nisbett, and P. R. Thagard, *Induction: Processes of inference, learning, and discovery*. MIT press, 1989.
- [11] D. Karaboga, "An idea based on honey bee swarm for numerical optimization," Technical report-tr06, Erciyes university, engineering faculty, computer ..., Tech. Rep., 2005.
- [12] E. Hancer, B. Xue, M. Zhang, D. Karaboga, and B. Akay, "Pareto front feature selection based on artificial bee colony optimization," *Information Sciences*, vol. 422, pp. 462 – 479, 2018.
- [13] H. Badem, A. Basturk, A. Caliskan, and M. E. Yuksel, "A new hybrid optimization method combining artificial bee colony and limited-memory bfgs algorithms for efficient numerical optimization," *Applied Soft Computing*, vol. 70, pp. 826 – 844, 2018.
- [14] A. Çalışkan, "Emg sinyalleri İçin hibrid Öznelik Çıkarma yöntemi geliştirilmesi," *Ömer Halisdemir Üniversitesi Mühendislik Bilimleri Dergisi*, vol. 8, pp. 652 – 664, 2019.
- [15] D. Karaboga and B. Basturk, "A powerful and efficient algorithm for numerical function optimization: artificial bee colony (abc) algorithm," *Journal of global optimization*, vol. 39, no. 3, pp. 459–471, 2007.
- [16] D. Karaboga and B. Akay, "A comparative study of artificial bee colony algorithm," *Applied mathematics and computation*, vol. 214, no. 1, pp. 108–132, 2009.
- [17] S. Aslan, "Time-based dance scheduling for artificial bee colony algorithm and its variants," *International Journal of Computational Intelligence Systems*, vol. 12, no. 2, pp. 597–612, 2019.
- [18] W.-f. Gao and S.-y. Liu, "A modified artificial bee colony algorithm," *Computers & Operations Research*, vol. 39, no. 3, pp. 687–697, 2012.
- [19] G. Zhu and S. Kwong, "Gbest-guided artificial bee colony algorithm for numerical function optimization," *Applied mathematics and computation*, vol. 217, no. 7, pp. 3166–3173, 2010.
- [20] L. Naranjo, C. J. Pérez, Y. Campos-Roca, and J. Martín, "Addressing voice recording replications for parkinson's disease detection," *Expert Systems with Applications*, vol. 46, pp. 286–292, 2016.
- [21] L. Naranjo, C. J. Pérez, J. Martín, and Y. Campos-Roca, "A two-stage variable selection and classification approach for parkinson's disease detection by using voice recording replications," *Computer methods and programs in biomedicine*, vol. 142, pp. 147–156, 2017.
- [22] D. Dua and C. Graff, "UCI machine learning repository," 2017. [Online]. Available: <http://archive.ics.uci.edu/ml>